

Autotune con voz de Miku

Afinar una voz y darle timbre de Miku sobre el phase vocoder de Dolson (DSP clásico)

Procesamiento Digital de Señales e Imágenes (INFB6063) - UTEM 2026-1

Francisco Alejandro Pinto Abraham - RUT 21.571.239-7

Artículo base: M. Dolson, "The Phase Vocoder: A Tutorial", CMJ 10(4), 1986

github.com/k0ngan/mikustromp

1. El problema

- Queremos un AUTOTUNE: tomar una voz cantada y dejarla afinada y con voz de Miku.
- Afinar = mover el tono a la nota correcta SIN acelerar/frenar la voz (conservar duración).
- Darle voz de Miku = cambiar el TIMBRE (formantes) sin cambiar la interpretación.
- La vía ingenua (remuestreo) mueve el tono PERO cambia la duración y corre los formantes
 - (efecto "ardilla").
- Objetivo: desacoplar tono, duración y timbre con DSP clásico.

2. El motor: phase vocoder de Dolson (1986)


- Analiza la señal con la STFT: por banda, separa magnitud y FASE.
- La fase da la FRECUENCIA INSTANTÁNEA (diferencia de fase entre tramas, mod 2π).
- Time-stretch: re-sintetizar con un salto distinto, acumulando la fase -> cambia la
 - duración sin tocar el tono. Pitch-shift = time-stretch + remuestreo.
- Es el motor que usa el autotune para corregir el tono conservando la duración.
- Limitaciones que reporta: phasiness y emborronado de transitorios.

3. Relación con el curso

- STFT y enventanado Hann -> Unit 2 - L1
- Espectro, magnitud y fase de la DFT / frecuencia instantánea -> Unit 1 - L2/L3
- Síntesis por superposición (overlap-add) -> Unit 2 - L1/L2
- Pitch-shift = stretch + remuestreo -> Unit 1 - L3
- Seguimiento de tono f_0 (autocorrelación / pYIN) -> Unit 1 - L1/L2
- Snap a la escala (f_0 -> nota MIDI) y registro de Miku -> logaritmos de frecuencia
- Formantes y timbre de Miku (máscara $H[k]$) -> Unit 2 - L3 + cepstrum. Sin ML.

4. Reproducción del motor: duración cambia, tono no

Reproducción phase vocoder (Dolson 1986): la duración cambia, el tono NO




5. Extensión propia: PV + formantes

- El pitch-shift básico mueve los formantes junto con los armónicos.
- Idea: re-imponer la ENVOLVENTE espectral tras cambiar el tono.
- Se estima la envolvente por CEPSTRUM (lifter de baja frecuencia).
- Máscara de corrección: $H[k] = \text{env_objetivo} / \text{env_actual}$ (acotada en dB).
- Sirve para dos cosas: mantener TU timbre al afinar, y luego imponer el de MIKU.
- Es filtrado en frecuencia (Unit 2 - L3) guiado por cepstrum. Sin ML.


6. El autotune, paso a paso

- 1) Seguir el TONO de la voz cuadro a cuadro (pYIN / autocorrelación).
- 2) SNAP: pasar f_0 a nota MIDI y pegarlo a la nota más cercana de la escala.
- 3) CORREGIR el tono variable en el tiempo con el phase vocoder + formantes
 - (conserva la duración por overlap-add).
- 4) REGISTRO de Miku: subir octavas enteras hasta el rango agudo (conserva la melodía).
- 5) TIMBRE de Miku: imponer su envolvente de formantes ($H = \text{env_Miku} / \text{env_voz}$).
- Perillas: escala, strength, retune_speed (T-Pain vs glissando), miku_amount, octava.

7. Snap: el tono se pega a la escala




8. Resultado: afinación antes vs después



Error de afinación medio: 42 -> 5 cents | duración conservada (0%)

9. Resultado: timbre de Miku (formantes)






La envolvente de la salida se acerca a la de Miku: LSD 5.3 -> 3.3 dB

10. Robustez con voz real de micrófono

- Problema real: una toma de micrófono venía muy floja, con un click al inicio y mucho silencio.
- Acondicionado de la voz: quita DC, pasa-altos, saca el click y normaliza por pico ROBUSTO.
- Registro de Miku automático: una voz grave (~ 120 Hz) se sube +2 octavas (~ 490 Hz).
- Compuerta de silencios: no se sintetiza voz en las pausas (evita ruido tonal / warble).
- Sin esto la salida quedaba grave (no sonaba a Miku) y con artefactos; ahora suena limpia.

11. Aplicación secundaria: Miku Stomp (guitarra)

Miku Stomp: voz sintetizada por método (misma melodía de guitarra)



12. Discusión y conclusiones

- Logrado: autotune que afina (42 -> 5 cents), conserva la duración y da timbre de Miku.
- Lo más complejo: el registro automático + acondicionar la voz y evitar el warble en silencios.
- Falla: tomas muy silenciosas/graves o saltos de tono enormes degradan el phase vocoder.
- Conceptos clave: STFT, fase/frecuencia instantánea, overlap-add, cepstrum, muestreo, autocorrelación.
- Trabajo futuro: tiempo real (sounddevice/plugin), polifonía, RVC/so-vits (solo mención).
- Código, informe, audios y cuaderno: github.com/k0ngan/mikustromp